

打ち負かし問題と信頼性主義

谷川綜太郎

千葉大学

2025 年 11 月 29 日

打ち負かし問題

知識の価値をめぐる議論 [12, 16, 6] において提起された問題に、**打ち負かし問題 (Swamping Problem)**と呼ばれるものがある。

これは、認識的価値に関する**三つの理論的前提**を同時に受け入れることで生じるトリレンマ¹をどのように解消するかという問題である。

¹トリレンマとして解釈する方法は [11] に由来する。

メノンテーゼ

メノンテーゼ (Meno's Thesis)

知識 (knowledge) は、単なる真なる信念 (mere true belief) よりも高い認識的価値を持つ。

われわれは単に真理を信じていることよりも、知っていることを望む。この背後にある直観を定式化したものがメノンテーゼ²。

これを認識的価値の差ではなく、**実用的価値の差**に過ぎない考える立場もある。しかし、実用性を度外視した状況（たとえば基礎科学やうわさ話）でも、われわれは単なる真なる信念よりも知識を望むように思われる。

²プラトン『メノン』でのやりとりに由来する。

真理主義 (Veritism)

認識的価値の唯一の源泉は真なる信念であり、信念が持ちうる他の性質に伴う認識的価値は、真なる信念というより基本的な認識的価値に対する**道具的価値 (instrumental value)**に過ぎない。

道具的価値

X が Y に対する道具的価値を持つ iff X が (価値ある) Y を獲得するための**手段**である。

たとえば、ゲームで良い選択をすることが、ゲームで勝利するための**手段**である場合、前者は後者に対する道具的価値を持つ。

この考えのもとでは、**正当化された信念**や**信頼できる仕方**で得られた**信念**に価値があるのは、それらを得ることが真なる信念を得るための**手段**として機能するからである。

打ち負かしテーゼ

打ち負かしテーゼ (Swamping Thesis)

もしある性質 F の価値が、別の性質 G の価値に対する道具的価値に過ぎず、かつ既に G が得られているなら、 F は**価値を付加しない**。

たとえば、ゲームで良い選択をすることの価値が、ゲームで勝利することの価値に対する道具的価値に過ぎず、かつ既に勝利しているなら、良い選択をしたという事実は**価値を付加しない**³。

これも正しいように思われる⁴。

³もしこれが何らかの価値（たとえばゲーム内容の充実などの価値）を付加するように見えるなら、道具的価値以外の価値を見いだしていることになる。

⁴打ち負かしテーゼを受け入れると不合理な帰結を招くため、受け入れるべきではないという議論 [1] もあるが、この議論は混乱している可能性が高い [2]。

打ち負かし問題

打ち負かし問題

- ① **メノンテーゼ:** 知識は、単なる真なる信念よりも高い認識的価値を持つ。
- ② **真理主義:** 認識的価値の唯一の源泉は真なる信念であり、信念が持ちうる他の性質に伴う認識的価値は、真なる信念というより基本的な認識的価値に対する道具的価値に過ぎない。
- ③ **打ち負かしテーゼ:** もしある性質 F の価値が、別の性質 G の価値に対する道具的価値に過ぎず、かつ既に G が得られているなら、 F は価値を付加しない。

この三つの理論的前提を同時に受け入れることで、**トリレンマ**が生じる。

何が間違っているのか？⁵

⁵厳密に言うと、打ち負かし問題を生じさせるのは道具主義的な真理主義（真なる信念の基本的価値と、それに対する道具的価値のみを認める立場）であり、道具主義を放棄することで打ち負かしを回避できるという主張もある [14]。

打ち負かし問題

ラリサ（都市の名前）に向かう途中の分岐で、

- 正しい方向を信じることには価値があり、
- 信頼できる案内システムによって案内された方向を信じることには、正しい方向を信じることに対する道具的価値がある。

しかし、既に正しい方向を信じている場合、それが信頼できる案内システムによって案内されたという事実は価値を付加しない。

コーヒーが好きな人にとって、

- 美味しいコーヒーを飲むことには価値があり、
- 信頼できるコーヒーメーカーによって淹れられたコーヒーを飲むことには、美味しいコーヒーを飲むことに対する道具的価値がある。

しかし、既に美味しいコーヒーを飲んでいる場合、それが信頼できるコーヒーメーカーによって淹れられたという事実は価値を付加しない。

有望だとされている応答

修正主義的な応答

メノンテーゼは修正される必要がある。すなわち、真なる信念よりも高い認識的価値を持つものは、知識ではなく（別の認識的価値） X である。

X の典型的な候補としては、**理解（understanding）**（信念間の構造的関係の把握を伴うため、さらなる価値がある）[6]が挙げられる。

この応答は興味深いが、あくまでも**最終手段**（打ち負かし問題を解決できる有望な知識理論がないときにのみ選択されるべき手段）として理解されるべきである。

有望だとされている応答

徳理論的な応答

知識とは、自らの有徳な知的能力（性格）によって得られた真なる信念である。したがって、知識を得ることは**称賛（credit）**に値する行為であり、知的な**達成（achievement）**を構成するため価値がある [12, 16, 13, 4]。

この応答は強力だが、**知識への要求が厳しくなりすぎる**⁶ ほか、**真理主義を放棄しなければならない**という代償⁷もある。

⁶自らの知的能力をほとんど発揮しなくても、信頼できるプロセスを通して信念を形成すれば、知識を得ることはできるように思われる。

⁷真理主義の魅力は、真理の獲得に貢献するものにだけ認識的価値を見いだすところにある。しかし、知的達成などの要素（これらは真理の獲得に貢献するものではない）にまで価値を見いだすなら、この魅力は失われてしまう。

他方で、もし知識に関して**信頼性主義 (Reliabilism)**⁸に留まるなら、このような代償を支払う必要はない。

信頼性主義

知識とは、信頼できる仕方（すなわち、真なる信念を生み出す傾向がある仕方）で生み出された真なる信念である。

しかし、信頼性主義は、**打ち負かし問題に対処することが特に難しい**と考えられてきた⁹。

⁸信頼性主義に徳理論的な含意を持たせる方法（徳信頼性主義）[12, 13, 4]はあるが、ここではそのような含意を持たせない、純粋な信頼性主義を想定している。

⁹打ち負かし問題はもともと、信頼性主義の問題だと考えられていた [12, 16]。

条件付き確率による解決

そうした中で、信頼性主義者 [3] によって提案された画期的な方法として、**条件付き確率による解決 (Conditional Probability Solution, CPS)**と呼ばれるものがある。

条件付き確率による解決

知識（信頼できる仕方で得られた真なる信念）が存在する状況は、知識未満の真なる信念（信頼できない仕方で得られた真なる信念）が存在する状況と比べて、**将来的にも同じタイプの真なる信念が得られる確率が高い**ため、より認識的な価値が高い。

この方法がうまくいけば、**余計な代償を支払わずに**、打ち負かし問題を解決できる可能性がある。本発表では、この可能性を検討してみたい。

条件付き確率による解決

- ① **信頼できる案内システムによって案内された正しい方向を信じている状況**
- ② **信頼できない案内システムによって案内された正しい方向を信じている状況**

前者は後者と比べて、**将来的にも（次の分岐でも）正しい方向を信じている確率が高いため、より価値が高い。**

- ① **信頼できるコーヒーメーカーによって淹れられた美味しいコーヒーを飲んでいる状況**
- ② **信頼できないコーヒーメーカーによって淹れられた美味しいコーヒーを飲んでいる状況**

前者は後者と比べて、**将来的にも美味しいコーヒーを飲んでいる確率が高いため、より価値が高い。**

条件付き確率による解決

CPS は、次の条件が成り立つところで成り立つことが保証されている [3]。

CPS が成り立つ経験的条件

- ① **非一回性 (Non-Uniqueness)** : 同じタイプの問題は、何度も現れる傾向がある。
- ② **時間横断的なアクセス (Cross-Temporal Access)** : 一度利用できた方法は、将来的にも利用できる傾向がある。
- ③ **学習 (Learning)** : 一度成功した方法は、繰り返し利用される傾向がある。
- ④ **一般性 (Generality)** : ある時点で信頼できた方法は、将来の別の時点でも信頼できる傾向がある。

われわれの世界では「**通常 (normally)**」これらの条件が成り立つため、CPS も「**通常**」成り立つことが保証されている。

条件付き確率による解決

もっとも、これらの条件は「常に (always)」成り立つわけではないため、CPS も「常に」成り立つわけではない¹⁰。

しかし、われわれの日常的な推論が「阻却可能 (defeasible)」である¹¹ことを考えると、**メノンテーゼを支持する理由としては十分**である [9]。

¹⁰このような反論については [7] を参照のこと。

¹¹たとえば、日常的な推論では、「鳥は飛ぶ」という一般化を行っても、ペンギンのような例外が現れたら取り下げることがある [9]。このような阻却可能性を認めるなら、「知識にはさらなる価値がある」という直観も阻却可能な一般化として理解できる。

なぜ知識の価値だと言えるのか？

しかし、CPS に対してはどうしても次のような疑問が浮かぶ。

CPS に対する疑問

CPS は、**知識が存在する状況の価値**を説明しているだけであり、**知識の価値**を説明していないのではないか？

たとえば、信頼できるコーヒーメーカー（RM）によって淹れられたコーヒー（RC）を飲んでいる状態で、将来的にも美味しいコーヒーを飲んでいる確率が高いのは、**RM の効果であり、RC の効果ではない**、のではないか？

なぜ知識の価値だと言えるのか？

これに関連した疑問として、次のような疑問 [5] がある。

CPS に対する疑問*

信頼できる方法 (RM) が利用できるなら、**それを利用して** (すなわち、信頼できる仕方で) 信念を形成した場合 (RB) にも、**それを利用せずに** (すなわち、信頼できない仕方で) 信念を形成した場合 (UB) にも、将来的に真なる信念が得られる確率は**変わらない**、のではないか？

しかし、こうした疑問に対しては、次のように応答できる [8]。すなわち、「**学習**」の条件により、信頼できない方法が (一度でも) 利用された状況では、繰り返しその方法が利用される可能性が高いため、実質的には (真なる信念が得られる) 確率が低下する。したがって、**RM+UB よりも RM+RB のほうが条件付き確率を高める効果を持つ**。ここに、RB の果たす役割がある。

なぜ知識の価値だと言えるのか？


しかし、それでもなお疑問が残るのは、**確率上昇に対する RB の貢献とは具体的に何なのか**、ということである。

たとえば、RM は真なる信念を**道具的に生み出す**ことで、真なる信念が得られる確率上昇に貢献する。したがって、そこには将来の真なる信念から派生した**道具的価値**がある。

しかし、RB は真なる信念を**道具的に生み出す**わけではない [15]。したがって、そこには将来の真なる信念から派生した**道具的価値**があるわけではない。

だとすると、RB は将来の真なる信念に対して**どのような関係**を持ち、そこから**どのような派生的価値**を得ているのだろうか？

なぜ知識の価値だと言えるのか？



指標的価値

CPS の支持者 [8] はこうした疑問に対して、**指標的価値 (indicator value)** という種類の価値 [17] を導入して応答している。

指標的価値


X が Y に対する指標的価値を持つ iff X が (価値ある) Y を**示している (indicating)**。

たとえば、健康診断の良い結果は、健康を道具的に生み出すわけではないが、健康を**示している**という点で、健康から派生した価値を持つ。

このように、われわれの価値体系では、道具的關係による価値の派生だけでなく、**指標的關係による価値の派生**も認めることができる。

この考えに基づくなら、知識は将来の真なる信念を**示している**という点で、将来の真なる信念から派生した価値を持つ、と考えることができる。

指標的価値



指標的価値

「たとえば、ある健康診断の結果が、患者の健康状態が良いことを**示しており (indicate)**、患者の健康状態が良いことが、本質的に良いと仮定せよ。この場合、その検査結果自体が（外在的に）良いと言いたくなるかもしれない」[17, 強調は引用者]

「CP 解決の背後にある考えは、知識がまさにその意味でさらなる価値を持つというものである。すなわち、知識のさらなる価値は、知識が何か良いもの、すなわち将来の真なる信念（これは真理主義的な枠組みにおいて最終的な価値を持つものである）を**示している (indicating)** ことから派生している。これは道具的価値の一種ではないが、それでもやはり外在的価値の一種である」[8, 強調は引用者]

しかし、**この価値は正式な価値のカテゴリーを構成できるだろうか？**

指標的關係の多義性

細かく観察してみると、**指標的關係には多義性がある**ように思われる。

- ① 健康診断の結果が健康を「示している」と言うとき、そこで意味されていることは、健康診断の結果が現在の健康状態を**反映する傾向**があり、それが健康である、ということである。
- ② 現在の知識が将来の真なる信念を「示している」と言うとき、そこで意味されていることは、現在の信念の性質が将来の信念の真偽を**予測する傾向**があり、それが真である、ということである。

これらは明らかに**異なる種類の関係**であるため、前者における価値の派生と、後者における価値の派生を、類比的に語ることはできない。(予測的關係は比較的弱い関係に見える。)

指標的關係の多義性

- 温度計が適温を「示している」と言うとき、そこで意味されていることは、温度計が現在の温度を**反映する傾向**があり、それが適温である、ということである。
- 黒い雲がその後の雨を「示している」と言うとき、そこで意味されていることは、雲の状態がその後の天気を**予測する傾向**があり、それが雨である、ということである。
- 観測データが理論 T を「示している」と言うとき、そこで意味されていることは、観測データが何らかの理論を**証拠付ける傾向**があり、それが T である、ということである。
- 発熱が感染を「示している」と言うとき、そこで意味されていることは、症状が身体内の状態を**原因として示す傾向**があり、それが感染である、ということである。

このような多義性を考慮すると、**指標的価値というカテゴリー自体が成立していない**ように思われる。

指標的関係の多義性

もっとも、**統一的に解釈する方法**は考えられる。たとえば、「 X が Y を示している」という関係を、次のように解釈する方法が考えられる。

- ① X が Y を因果的に引き起こすわけではない。
- ② $P(Y | X) > P(Y)$ が成り立つ。

しかし、この解釈は、**明らかに価値が派生しない関係まで拾ってしまう**。

たとえば、「食事内容に気を付けている」(P) 場合に「運動を習慣にしている」(Q) 確率が高い、という傾向が成り立つとしても、 P と Q が「健康への意識が高い」という共通の要因によってもたらされているに過ぎず、 P と Q の間に**それ以上の関係がない**なら、 Q から P へ価値が派生するという考えは奇妙である。

指標的関係の多義性

このような「拾いすぎ」を避けるための追加条件として、**タイプの関係 (X と Y は同じタイプの現象である) を要求する方法**も考えられる。

この方法を用いれば、「現在の分岐で正しい方向を信じている」と「将来の分岐で正しい方向を信じている」のような関係は包摂しつつ、「食事内容に気を付けている」と「運動を習慣にしている」のような関係は排除できる。

しかし、この方法を用いれば、「健康診断の良い結果」と「健康」のような関係も同時に排除されてしまうため、もはや指標的関係の解釈ではなくなってしまう。

かわりに、このような関係を「指標*的關係」と呼び、指標*的關係による価値の派生を認める方法はあるかもしれないが、それはCPSを正当化するためだけの**恣意的な決定**であるように思われる。

指標的価値の所在

また、何らかの仕方で指標的關係をうまく定義できたとしても、**次のテーゼが真である限り、この戦略は失敗している**ように思われる。

X が価値あるものを示しているとき、派生的に価値があるのはその**状況**であり、**X (indicator)** ではない¹²。

たとえば、適温に価値があるとき、温度計が適温を示している**状況**には価値がある。しかし、だからといって、適温を示している**温度計 (indicator)** に価値がある（そこに価値が付加される）わけではない。

したがって、知識の指標的機能に訴えても、知識の価値を説明する根拠は得られない。

¹²もし指標 (indicator) に価値があるなら、それはおそらく情報的価値であり、そのような価値は、示しているものが何であれ（すなわち、良いことであれ悪いことであれ）付随するだろう。（したがって、「さらなる価値」の説明には使えない。）

以上の議論が正しければ、**CPS はやはり知識の価値を説明できていない**ように思われる。

単なる真なる信念 (TB) が存在する状況と比べて、信頼性主義的な知識 (RTB) が存在する状況には、確かに何らかの良さがある。この良さ自体は認められるべきだが、それは RTB が良いことを意味しない。

この結論を直感的に理解するために、信頼できる仕方で淹れられたコーヒー (RC) と信頼できない仕方で淹れられたコーヒー (UC) が**同時に存在する状況**を想像してみてほしい。このような状況下で、RC と UC の美味しさがまったく同じであると保証されている場合、あえて RC を選ぶ強力な理由は存在しないように思われる¹³。

¹³もしここで RC に強力な魅力を感じる人がいるなら、その人はよりリスク回避的 (risk-averse) な傾向 [10] を持っているのかもしれない。

おそらく、メノンテーゼの根底にある直観は、**反省的な知識**や**有徳な知識**、あるいは**体系的な知識**などのより高度な知識へと向けられたものであり、信頼性主義的な知識へと向けられたものではない。

したがって、私が提案したい信頼性主義者の対応は、**信頼性主義的な理論を基本的な知識理論としつつも、それと同時に、そのような高度な知識を（限定された種類の知識として）探究すること**である。

もしそれらに（打ち負かされない）価値があることがわかれば、**推論の阻却可能性**に関する主張と組み合わせることで、**メノンテーゼを支持できる可能性**がある。（すなわち、高度な知識に対する直観に基づく、阻却可能な一般化として理解できる可能性がある。）

いずれにしても、信頼性主義の枠組み**だけ**で打ち負かし問題に対処しようとすることは、有望ではないだろう¹⁴。

¹⁴CPSの支持者[3]は、価値自律化（Value Autonomization）というプロセスに訴える別の説明も展開しているが、こちらについては客観性を欠くという反論[7]がある。

- [1] J. Adam Carter and Benjamin Jarvis. Against swamping. *Analysis*, 72 (4):690–699, 2012.
- [2] Julien Dutant. In defence of swamping. *Thought: A Journal of Philosophy*, 2(4):357–366, 2013.
- [3] Alvin Goldman and Erik Olsson. Reliabilism and the value of knowledge. In *Epistemic Value*. Oxford University Press, 2009.
- [4] John Greco. *Achieving Knowledge: A Virtue-Theoretic Account of Epistemic Normativity*. Cambridge University Press, 2010.
- [5] Joachim Horvath. Why the conditional probability solution to the swamping problem fails. *Grazer Philosophische Studien*, 79(1): 115–120, 2009.
- [6] Jonathan Kvanvig. *The Value of Knowledge and the Pursuit of Understanding*. Cambridge University Press, 2003.

- [7] Jonathan Kvanvig. The swamping problem redux: pith and gist. In *Social Epistemology*. Oxford University Press, 2008.
- [8] Erik Olsson. In defense of the conditional probability solution to the swamping problem. *Grazer Philosophische Studien*, 79(1):93–114, 2009.
- [9] Erik Olsson. Reply to kvanvig on the swamping problem. *Social Epistemology*, 25(2):173–182, 2011.
- [10] Richard Pettigrew. Veritism, epistemic risk, and the swamping problem. *Australasian Journal of Philosophy*, 97(4):761–774, 2019.
- [11] Duncan Pritchard. What is the swamping problem. In *Reasons for Belief*. Cambridge University Press, 2011.
- [12] Wayne Riggs. Reliability and the value of knowledge. *Philosophy and Phenomenological Research*, 64(1):79–96, 2002.
- [13] Ernest Sosa. *A Virtue Epistemology: Apt Belief and Reflective Knowledge, Volume I*. Oxford University Press, 2007.

- [14] Kurt Sylvan. Veritism unswamped. *Mind*, 127(506):381–435, 2018.
- [15] Markus Werning. The evolutionary and social preference for knowledge: How to solve meno's problem within reliabilism. *Grazer Philosophische Studien*, 79(1):137–156, 2009.
- [16] Linda Zagzebski. The search for the source of epistemic good. *Metaphilosophy*, 34(1–2):12–28, 2003.
- [17] Michael Zimmerman. Intrinsic vs. extrinsic value. In *The Stanford Encyclopedia of Philosophy*. Metaphysics Research Lab, Stanford University, winter 2002 edition, 2002.